

Maia José Dedano Castañeda

C.U. 157500

Examen Final

1. Gradiente Conjugado.

1.1.P.D. Si $p_1, p_2, \dots, p_l \neq \vec{0}$ satisfacen que:

$$p_i^T A p_j = 0 \quad \forall i \neq j$$

y A es simétrica positiva definida, entonces las vectores son l.i.

Dem.

Lo anterior implica demostrar que para $\alpha_i \in \mathbb{R}$ con $i=1, \dots, l$ tenemos

$$\sum_{i=1}^l \alpha_i p_i = \vec{0} \Rightarrow \alpha_i = 0 \quad \forall i.$$

Ahora, procedamos diciendo que $\exists \alpha_j \neq 0$ con α_j fija tenemos por otro lado

$$\sum_{i=1}^l \alpha_i p_i = \vec{0}$$

tenemos a la matriz A simétrica positiva def., multiplicando por la izquierda

$$A \sum_{i=1}^l \alpha_i p_i = A \vec{0} \Rightarrow \sum_{i=1}^l A \alpha_i p_i = A \vec{0} = \vec{0}$$

mult. p_j^T por la izquierda tenemos

$$p_j^T \sum_{i=1}^l \alpha_i A p_i = p_j^T \vec{0} \Rightarrow \sum_{i=1}^l \alpha_i p_j^T A p_i = 0$$

por hipótesis $p_j^T A p_i = 0 \quad \forall i \neq j$

$$\Rightarrow \sum_{i=1}^l \alpha_i p_j^T A p_i = \alpha_j p_j^T A p_j = 0$$

sabemos además que $x^T A x > 0 \quad \forall x \in \mathbb{R}^l$
entonces $\alpha_j p_j^T A p_j = 0 \Leftrightarrow \alpha_j = 0$ ∇

$\therefore \alpha_j = 0$ así tenemos. $\sum_{i=1}^l \alpha_i p_i = \vec{0}$

con $\alpha_i = 0 \quad \forall i=1, \dots, l$

$\therefore \{p_1, \dots, p_l\}$ es l.i. \blacksquare

1.2. Dado el resultado 1.1.
¿Por qué el gradiente conjugado converge a lo más
más en n iteraciones?

Recordemos el lema:

"Para cualquier $x_0 \in \mathbb{R}^n$ la sucesión $\{x_k\}$ generado
por el algoritmo de gradiente conjugado converge
a la solución x^* del sistema lineal en a lo
más n pasos."

Para nuestro caso tomamos el sistema lineal
definido anteriormente con $\sum_{i=1}^n \alpha_i p_i$
considerando la sucesión $x_{k+1} = x_k + \alpha_k p_k$
que usa el método.

no $0 \neq b \in \mathbb{R}^n$ sup obvious normobway, normo
obol auto way normat diff id

$$0 = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i$$

if entradaq norma A, normo de b, normat
obvimp de ng obvimp

$$0 = 0A = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i \Leftrightarrow 0A = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i$$

normat obvimp de ng norm

$$0 = 0A^T \cdot 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i \Leftrightarrow 0^T \cdot 0 = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i$$

$$0 = 0A^T \cdot 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i \Leftrightarrow 0^T \cdot 0 = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i$$

$$0 = 0A^T \cdot 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i \Leftrightarrow 0^T \cdot 0 = 0 \cdot b = \sum_{i=1}^n 0 \cdot b_i$$

291 x + 0 < x A x sup norma norma
0 = 0 \Leftrightarrow 0 = 0 \cdot A^T \cdot 0 \cdot b

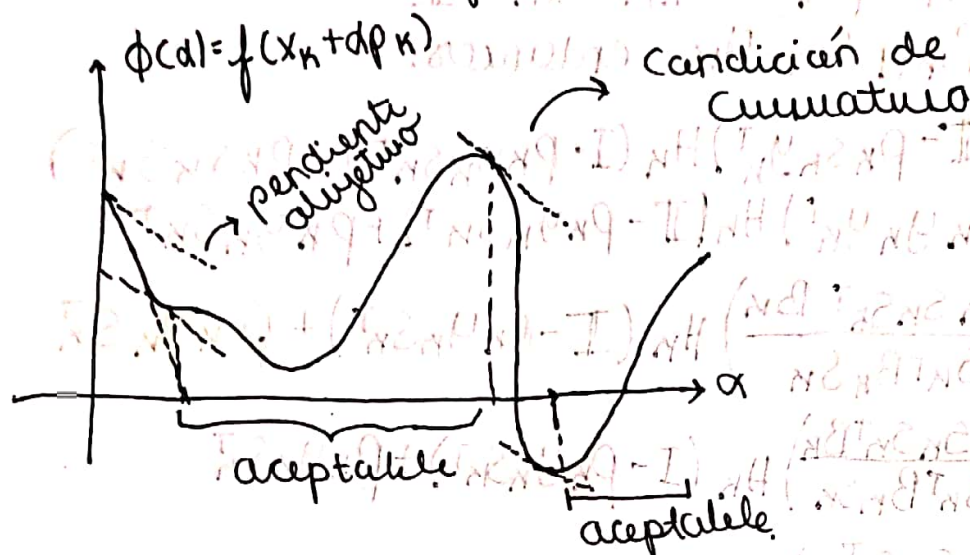
$$0 = 0 \Leftrightarrow 0 = 0 \cdot A^T \cdot 0 \cdot b$$

2. Quasi-Newton.

2.1. Muestre que la segunda condición fuerte de Wolfe implica la condición de curvatura

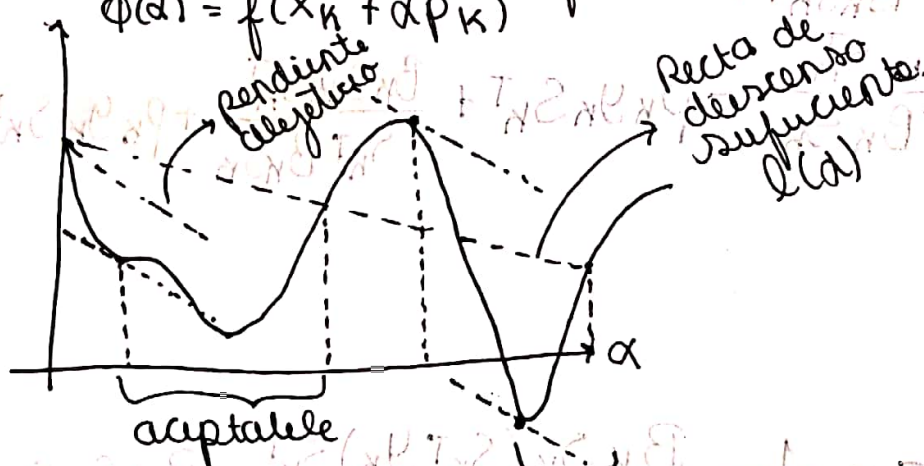
$$S_k^T y_k > 0$$

(Barrido de dibujos.)



condiciones de Wolfe

$$\phi(\alpha) = f(x_k + \alpha p_k)$$



Dem.

tenemos
es:

que la segunda condición fuerte de Wolfe

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|$$

$$\Rightarrow \nabla f(x_k + \alpha_k p_k)^T p_k \geq -c_2 |\nabla f(x_k)^T p_k| = -c_2 \nabla f(x_k)^T p_k$$

si p_k es la dirección de descenso tenemos:

$$\nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f(x_k)^T p_k = (c_2 - 1) \nabla f(x_k)^T p_k > 0$$

Porque tenemos $c_2 < 1$, si mult. por α_k ambas

lados, tenemos que $s_k = \alpha_k p_k$ y $y_k = \nabla f(x_k + \alpha_k p_k) - \nabla f(x_k)$

2.2. Verifique que B_{k+1} y H_{k+1} son inversas la una de la otra.

Dem.

tenemos que probar que $B_{k+1} H_{k+1} = I$

notemos que $B_{k+1} s_k = y_k$ entonces:

$$\begin{aligned} B_{k+1} H_{k+1} &= B_{k+1} ((I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T) \\ &= (B_{k+1} - \rho_k y_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= \left(B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} \right) H_k (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= \left(B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} \right) H_k (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= \left(I - \frac{B_k s_k s_k^T}{s_k^T B_k s_k} \right) (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= I - \frac{B_k s_k s_k^T}{s_k^T B_k s_k} - \rho_k y_k s_k^T + \frac{B_k s_k s_k^T}{s_k^T B_k s_k} + \rho_k y_k s_k^T \\ &= I \quad \blacksquare \end{aligned}$$

Otro.

$$\rho_k \frac{B_k s_k s_k^T}{s_k^T B_k s_k} y_k s_k^T = \frac{1}{s_k^T y_k} \frac{B_k s_k (s_k^T y_k) s_k^T}{s_k^T B_k s_k} = \frac{B_k s_k s_k^T}{s_k^T B_k s_k}$$